

Curso de Engenharia de Computação

ECM253 – Linguagens Formais, Autômatos e Compiladores

Modelos de computação – Linguagens e gramáticas



Slides da disciplina ECM253 – Linguagens Formais, Autômatos e Compiladores

Curso de Engenharia de Computação

Instituto Mauá de Tecnologia – Escola de Engenharia Mauá

Prof. Marco Antonio Furlan de Souza

[<marco.furlan@maua.br>](mailto:marco.furlan@maua.br)

Agenda

- Modelos de computação
- Gramáticas e linguagens

Algoritmos e computação

■ O conceito de algoritmo

- Um algoritmo descreve um **procedimento computacional** que deve ser:
 - **Definido**: em cada ponto em que estiver, sempre há um **próximo passo** determinado – é processo **determinístico**;
 - **Finito**: após um **conjunto finito** de passos, o **algoritmo termina**;
 - Se o algoritmo termina ele deve ser **conclusivo** – gerar um resultado não ambíguo.
- A questão é: **como modelar um computador** e seu **processo de execução de algoritmos**?
- Para isso, é necessário **abstrair** o **processo de computação** por si próprio.

Modelo geral de computação

■ Computador como função de transição

- **Qualquer computador** (ou sistema físico) pode ser modelado como tendo, em um certo **instante** de **tempo**, um **estado** específico $s \in S$ de algum **espaço de estados** S (finito or infinito);
- E, em **qualquer instante**, o computador pode **receber** um **símbolo** de **entrada** $i \in I$ e **produzir** um **símbolo** de **saída** $o \in O$, onde I e O são conjuntos de símbolos (cada símbolo pode codificar uma quantidade arbitrária de dados);
- Um **computador** pode, então, ser **modelado** simplesmente como uma **função de transição** $T : S \times I \rightarrow S \times O$, onde I e O são conjuntos de símbolos;
- Todo modelo de computação pode ser visto como um caso especial desta formulação geral.

Modelos de computação

■ Três modelos importantes:

- **Gramáticas e linguagens:** utilizadas para gerar palavras de uma **linguagem** e para **reconhecer** se uma **palavra** faz parte da **linguagem**. Gramáticas são muito importantes na **teoria** e **construção** de **compiladores**;
- **Máquinas de estado finito:** possuem diversos tipos e são caracterizadas por um conjunto de **estados**, um **alfabeto** de entrada e uma **função** de **transição de estados** que mapeia um **próximo estado** a um par composto por **estado** e **entrada** atuais. São utilizadas para **reconhecimento de linguagens** e modelagem de diversos tipos de máquinas;
- **Máquinas de Turing:** são utilizadas para reconhecer **conjuntos de expressões** complexos que não podem ser reconhecidos por máquinas de estados finito e também para **computar funções** numéricas teóricas.

Agenda

- Modelos de computação
- Gramáticas e linguagens

Alfabetos e cadeias

■ Alfabeto

Definição. Um **alfabeto** ou **vocabulário**, escrito como Σ , é um conjunto finito e não vazio de símbolos.

■ Cadeia

Definição. Uma **cadeia** é uma **sequência**, possivelmente vazia, de **comprimento finito** de elementos de Σ . A **cadeia vazia** ou **cadeia nula**, denotada por ϵ , é uma cadeia que não contém símbolo algum.

O conjunto de todas as cadeias sobre Σ é denotado por Σ^* . A cadeia vazia sempre pertence à Σ^* e, se não for o caso, utilizar a notação Σ^+ , que representa $\Sigma^* - \{\epsilon\}$.

Uma **linguagem** sobre Σ é um subconjunto de Σ^* , $L \subseteq \Sigma^*$.

Alfabetos e cadeias

■ Exemplos

- Alfabeto binário: $\Sigma = \{0, 1\}$;
- Letras minúsculas do alfabeto: $\Sigma = \{a, b, \dots, z\}$;
- Se $\Sigma = \{0, 1\}$, $\Sigma^0 = \{\epsilon\}$, $\Sigma^1 = \{0, 1\} = \Sigma$, $\Sigma^2 = \{00, 01, 10, 11\}$, $\Sigma^3 = \{000, 001, 010, 011, 100, 101, 110, 111\}$;
- O conjunto de todas as palavras sobre um alfabeto Σ é definido por $\Sigma^* = \Sigma^0 \cup \Sigma^1 \cup \Sigma^2 \cup \dots$;
- Se $\Sigma = \{0, 1\}$, $\Sigma^* = \{\epsilon, 0, 1, 00, 01, 10, 11, 000, \dots\}$;
- Se $\Sigma = \{0, 1\}$, $\Sigma^+ = \{0, 1, 00, 01, 10, 11, 000, \dots\}$.

Funções sobre cadeias

■ Comprimento

Definição. O **comprimento** de uma cadeia s é escrita como $|s|$ é o número de símbolos presentes em s . O comprimento da cadeia vazia é zero, $|\epsilon| = 0$;

■ Concatenação

Definição. A **concatenação** de duas cadeias s e t é escrita como st (ou $s||t$) e resulta em uma **cadeia** formada pela **justaposição** de t à s . O comprimento de uma cadeia obtida pela concatenação de duas cadeias s e t é igual à soma dos comprimentos de s e t : $|st| = |s| + |t|$.

Funções sobre cadeias

■ Replicação

Definição. Para cada **cadeia** w e para cada **número natural** i , a cadeia w^i é definida como:

$$\begin{aligned}w^0 &= \epsilon \\w^{i+1} &= w^i w\end{aligned}$$

■ Inversa de uma cadeia

Definição. Para cada cadeia w , a cadeia **inversa** de w , escrita como w^R é assim definida:

$$w^R = \begin{cases} \epsilon & \text{se } |w| = 0 \\ au^R & \text{se } |w| \geq 1 \wedge (\exists a)(\exists u)(a \in \Sigma \wedge u \in \Sigma^* \wedge w = ua) \end{cases}$$

Funções sobre cadeias

■ Exemplos

- $|\epsilon| = 0$;
- $|1001101| = 7$;
- Se $x = \text{good}$ e $y = \text{bye}$ então $xy = \text{goodbye}$;
- $a^0 b^3 = \text{bbb}$;
- $a^3 = \text{aaa}$;
- $(\text{bye})^2 = \text{byebye}$;
- Se $s = \text{roma}$, então

$$\begin{aligned}
 \text{roma}^R &= a(\text{rom})^R \\
 &= a m(\text{ro})^R \\
 &= a m o(r)^R \\
 &= a m o r(\epsilon)^R \\
 &= a m o r
 \end{aligned}$$

Relações sobre cadeias

- Subcadeia e subcadeia própria

Definição. Uma cadeia s é uma **subcadeia** de t se e somente se s **ocorre contigualmente** como parte de t .

Uma cadeia s é uma **subcadeia própria** de t se e somente se s ocorre contigualmente como parte de t e $s \neq t$.

- Prefixo e prefixo próprio

Definição. Uma cadeia s é um **prefixo** de t se e somente se $(\exists x \in \Sigma^*)(t = sx)$.

Uma cadeia s é um **prefixo próprio** de t se e somente se s é prefixo de t e $s \neq t$.

Relações sobre cadeias

- Sufixo e sufixo próprio

Definição. Uma cadeia s é um **sufixo** de t se e somente se $(\exists x \in \Sigma^*)(t = xs)$.

Uma cadeia s é um **sufixo próprio** de t se e somente se s é sufixo de t e $s \neq t$.

Relações sobre cadeias

■ **Exemplos**

- aaa é subcadeia (própria) de bbaaaacc;
- bbaaaacc é subcadeia de bbaaaacc;
- bbaaaacc não é subcadeia própria de bbaaaacc;
- bba é prefixo (próprio) de bbaaaacc;
- acc é sufixo (próprio) de bbaaaacc.

Linguagens

■ Linguagens e computação

- Uma **linguagem** L é um **conjunto** (finito ou infinito) de **cadeias** sobre um alfabeto Σ , $L \subseteq \Sigma^*$;
- Para uma definição computacional de uma linguagem, pode-se especificar:
 - **Um gerador da linguagem**: que enumere os elementos da linguagem ou
 - **Um reconhecedor da linguagem**: que decida se uma cadeia está ou não na linguagem, retornando V se estiver e F, caso contrário.
- Este problema, embora pareça simples, é tão geral quanto a própria noção de computação.

Linguagens

■ Exemplos de linguagens

- Seja $\Sigma = \{a, b\}$. $\Sigma^* = \{\epsilon, a, b, aa, ab, ba, bb, aaa, aab, \dots\}$. São exemplos de linguagens sobre Σ : $\emptyset, \{\epsilon\}, \{a, b\}, \{\epsilon, a, aa, aaa, aaaa, aaaaa\}$.
- Quando presentes, todos os b's são precedidos por todos a's:

$$L = \{w \in \{a, b\}^* : \text{quando presentes, a's precedem os b's em } w\} \\ = \{\epsilon, a, aa, aabbb, bbb, \dots\}$$

- Cadeias que terminam em a:

$$L = \{x : \exists y \in \{a, b\}^* (x = ya)\} = \{a, aa, bbba, ba, \dots\}$$

- Linguagem vazia (não contém cadeia alguma):

$$L = \{\} = \emptyset$$

- Linguagem contendo apenas a cadeia vazia:

$$L = \{\epsilon\}$$

Linguagens

■ Exemplos de linguagens

- Nenhum prefixo contém b:

$$L = \{w \in \{a, b\}^* : w \text{ não contenha } b \text{ em seu prefixo}\}$$

$$= \{\epsilon, a, aa, aaa, aaaa, aaaaa, aaaaaa, \dots\}$$

- Nenhum prefixo começa com b:

$$L = \{w \in \{a, b\}^* : \text{o prefixo de } w \text{ não se inicie por } b\}$$

$$= \{\epsilon, a, aa, aba, aaabb, abbaa, abbbabaa, \dots\}$$

- Todo prefixo começa com b:

$$L = \{w \in \{a, b\}^* : \text{toda cadeia } w \in \{a, b\}^* \text{ possui prefixo iniciado por } b\}$$

$$= \emptyset$$

Linguagens

■ Exemplos de linguagens

- Uso de replicação para definir uma linguagem:

$$\begin{aligned} L &= \{a^n : n \geq 0\} \\ &= \{\epsilon, a, aa, aaa, aaaa, \dots\} \end{aligned}$$

- Exemplo já apresentado, reescrito:

$$\begin{aligned} L &= \{a^m b^n : m, n \geq 0\} \\ &= \{\epsilon, a, aa, aabbb, bbb, \dots\} \end{aligned}$$

Operações sobre linguagens

■ Cardinalidade de uma linguagem

Teorema. Se $\Sigma \neq \emptyset$ então Σ^* é contavelmente infinita.

Demonstração. Os elementos de Σ^* podem ser enumerados lexicograficamente pelo procedimento a seguir:

- Enumerar todas as cadeias de tamanho zero, depois de tamanho um, de tamanho dois etc.;
- Enumerar as cadeias de mesmo tamanho de acordo com a ordem de dicionário;

Esta enumeração é infinita pois não existe uma cadeia mais longa em Σ^* . Assim, trata-se de uma enumeração infinita. \square

Operações sobre linguagens

- Quantas linguagens existem?

Teorema. *Existe um número incontavelmente infinito de linguagens.*

Demonstração. O conjunto de linguagens definida por Σ é $\wp(\Sigma^*)$. Sabe-se que o conjunto Σ^* é contavelmente infinito, mas o conjunto $\wp(\Sigma^*)$ não é contavelmente infinito pois pode-se, a partir de uma tentativa de enumeração de $\wp(\Sigma^*)$, determinar um novo e inédito elemento não previsto anteriormente, e assim por diante, contradizendo a proposta de um conjunto enumerado. A técnica utilizada para esta prova é a **diagonalização de Cantor**. \square

Operações sobre linguagens

■ Operações de conjuntos aplicadas às linguagens

- Como uma linguagem é um conjunto, todas as operações sobre conjuntos aplicam-se às linguagens. Seja, por exemplo:

$$\Sigma = \{a, b\}$$

$$L_1 = \{\text{cadeias com um número par de a's}\}$$

$$L_2 = \{\text{cadeias sem b's}\}$$

Então:

$$L_1 \cup L_2 = \{\text{todas as cadeias com apenas a's e cadeias contendo b's com um número par de a's}\}$$

$$L_1 \cap L_2 = \{\epsilon, aa, aaaa, aaaaaa, \dots\}$$

$$L_2 - L_1 = \{a, aaa, aaaaa, \dots\}$$

$$\neg(L_2 - L_1) = \{\text{cadeias com no mínimo um b}\} \cup \{\text{cadeias com número par de a's}\}$$

Operações sobre linguagens

- Concatenação de linguagens

- Sejam L_1 e L_2 duas linguagens definidas sobre algum alfabeto Σ . Sua **concatenação**, L_1L_2 é:

$$L_1L_2 = \{w \in \Sigma^* : \exists s \in L_1 (\exists t \in L_2 (w = st))\}$$

- Exemplo:

$$L_1 = \{\text{cat}, \text{dog}, \text{mouse}, \text{bird}\}$$

$$L_2 = \{\text{bone}, \text{food}\}$$

$$L_1L_2 = \{\text{catbone}, \text{catfood}, \text{dogbone}, \text{dogfood}, \text{mousebone}, \\ \text{mousefood}, \text{birdbone}, \text{birdfood}\}$$

Operações sobre linguagens

■ Fecho de Kleene

- Seja L uma linguagem sobre algum alfabeto Σ . O **fecho de Kleene** de L , L^* é:

$$L^* = \{\epsilon\} \cup \{w \in \Sigma^* : \exists k \geq 1 (\exists w_1, w_2, \dots, w_k \in L (w = w_1 w_2 \dots w_k))\}$$

- **Exemplo:**

$$\begin{aligned} L &= \{\text{cat}, \text{dog}, \text{fish}\} \\ L^* &= \{\epsilon, \text{dog}, \text{cat}, \text{fish}, \text{dogdog}, \text{dogcat}, \dots, \\ &\quad \text{fishdog}, \dots, \text{fishcatfish}, \text{fishdogfishcat}, \dots\} \end{aligned}$$

- L^* sempre conterá um **número infinito de cadeias** desde que L não seja igual a \emptyset ou $\{\epsilon\}$;
- Se L^* deve conter pelo menos um elemento de L , define-se: $L^+ = LL^*$.

Operações sobre linguagens

■ Inversa de uma linguagem

- Seja L uma linguagem sobre algum alfabeto Σ . A **inversa** de L , L^R é:

$$L^R = \{w \in \Sigma^* : w = x^R \text{ para algum } x \in L\}$$

- Basta inverter as cadeias de L .

Teorema. Se L_1 e L_2 são linguagens, então $(L_1 L_2)^R = L_2^R L_1^R$.

Demonstração.

$$\begin{aligned} (L_1 L_2)^R &= \{(xy)^R : x \in L_1 \wedge y \in L_2\} \\ &= \{y^R x^R : x \in L_1 \wedge y \in L_2\} \\ &= L_2^R L_1^R \end{aligned}$$



Gramáticas

■ Conceitos

- Uma **gramática formal** G é uma forma matemática precisa e compacta de definição de uma linguagem L ;
- Assim, dispensa a listagem de todas as cadeias legais de uma linguagem;
- Implica em um **algoritmo** que permite gerar todas as cadeias legais da linguagem, comumente de modo recursivo;
- Uma forma popular de descrever gramáticas recursivamente é a **gramática de estrutura frasal**, elaborada por Noam Chomsky na década de 1950.

Gramáticas

■ Gramática de estrutura frasal

Definição. *Uma gramática de estrutura frasal, $G = (V, \Sigma, R, S)$ é uma quádrupla na qual:*

- V é o **alfabeto** (ou vocabulário) da **linguagem** e contém símbolos (metasímbolos) que são utilizados apenas na definição da linguagem denominados de **não-terminais** (ou **variáveis da gramática**) e também símbolos **terminais**, que aparecem apenas nas cadeias da linguagem;
- Σ é o conjunto de **símbolos terminais**, $\Sigma \subset V$;
- R é um **conjunto** não vazio **de regras de produção** ou **regras de reescrita**, assim definido: $R \subset (V^* \times (V - \Sigma) \times V^*) \times V^*$, cujos pares (α, β) são escritos como $\alpha \rightarrow \beta$;
- S é o símbolo não-terminal **de partida** ou **inicial**, $S \in V - \Sigma$.

Gramáticas

- **Exemplo.** A gramática $G = (V, \Sigma, R, S)$, a seguir, gera uma linguagem de identificadores de uma linguagem de programação:

$$V = \{S, I, L, D, a, b, c, d, e, f, g, h, i, j, k, l, m, n, o, p, q, r, s, t, \\ u, v, w, x, y, z, \emptyset, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$$

$$\Sigma = \{a, b, c, d, e, f, g, h, i, j, k, l, m, n, o, p, q, r, s, t, \\ u, v, w, x, y, z, \emptyset, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$$

$$R = \{S \rightarrow I, I \rightarrow L, I \rightarrow IL, I \rightarrow ID, \\ L \rightarrow a, L \rightarrow b, \dots, L \rightarrow z, \\ D \rightarrow \emptyset, D \rightarrow 1, \dots, D \rightarrow 9\}$$

Derivação

■ Derivação direta

Definição. *Seja $G = (V, \Sigma, R, S)$ uma gramática. Para $\sigma, \psi \in V^*$, σ é dito **diretamente derivável** de ψ , escrito como $\psi \Rightarrow \sigma$, se existem cadeias ϕ_1 e ϕ_2 (incluindo cadeias vazias) tais que $\psi = \phi_1 \alpha \phi_2$ e $\sigma = \phi_1 \beta \phi_2$ e $\alpha \rightarrow \beta$ é uma produção de G . Quando $\psi \Rightarrow \sigma$ diz-se que ψ produz diretamente σ ou ainda que σ reduz-se diretamente à ψ .*

■ Derivação de cadeia

Definição. *Seja $G = (V, \Sigma, R, S)$ uma gramática. A cadeia ψ **produz** σ (ou σ reduz-se à ψ), escrita como $\psi \xRightarrow{*} \sigma$ se existem cadeias $\phi_0, \phi_1, \dots, \phi_n$, com $n \geq 0$, tais que $\psi = \phi_0 \Rightarrow \phi_1, \phi_1 \Rightarrow \phi_2, \dots, \phi_{n-1} \Rightarrow \phi_n = \sigma$. A relação $\xRightarrow{*}$ é o fecho transitivo reflexivo da relação \Rightarrow .*

Derivação

■ Exemplo

- Na gramática apresentada anteriormente, o símbolo de início é S . É a partir de uma produção em que ele aparece do lado esquerdo que se começa qualquer derivação;
- Assim, uma derivação de cadeia válida é a seguinte:

$$S \Rightarrow I \Rightarrow ID \Rightarrow IDD \Rightarrow LDD \Rightarrow aDD \Rightarrow a1D \Rightarrow a13$$

- Então, $S \xRightarrow{*} a13$.
- Esta gramática permite derivar 23q? e r2d2?

Linguagem gerada por uma gramática

■ Processo de geração de uma linguagem

- Uma **forma sentencial** é qualquer cadeia derivada a partir do não-terminal S ;
- A **linguagem L gerada** por uma gramática G é o conjunto de todas as formas sentenciais cujos símbolos são **terminais**:

$$L(G) = \{\sigma : S \xRightarrow{*} \sigma (\sigma \in \Sigma^*)\}$$

- Em outras palavras: uma linguagem é um subconjunto do conjunto de todas as cadeias (sentenças) terminais sobre Σ^* .

Teste seus conhecimentos

- (1) Elaborar uma gramática de estrutura frasal que gere cadeias para a linguagem $L = (11)^* 0$, o conjunto de todas as cadeias consistindo de algum número de concatenações de 11 com ele próprio, seguido finalmente por 0.
- (2) Elaborar uma gramática de estrutura frasal que gere a linguagem $L = \{0^n 1^n : n \in \mathbb{N}\}$.
- (3) Seja $V = \{S, A, B, a, b\}$ e $\Sigma = \{a, b\}$. Descobrir a linguagem gerada pela gramática $G = (V, \Sigma, R, S)$ quando:
 - a) $R = \{S \rightarrow AB, A \rightarrow ab, B \rightarrow bb\}$.
 - b) $R = \{S \rightarrow AB, S \rightarrow AA, A \rightarrow aB, A \rightarrow ab, B \rightarrow b\}$.
 - c) $R = \{S \rightarrow AB, A \rightarrow aBb, B \rightarrow bBa, A \rightarrow \epsilon, B \rightarrow \epsilon\}$.

Teste seus conhecimentos

- (4) Elaborar uma gramática de estrutura frasal para todas as cadeias binárias contendo o símbolo 1 seguido de um número ímpar de 0's.
- (5) Elaborar uma gramática de estrutura frasal para todas as cadeias binárias contendo um número de símbolos 1's diferente do número de símbolos 0's.
- (6) Elaborar uma gramática de estrutura frasal que gere todos os palíndromos sobre $\Sigma = \{0, 1\}$.

Hierarquia das linguagens

■ Classificação da gramáticas

- **Tipo 0.** São as denominadas **gramáticas irrestritas** ou **gramáticas de estrutura frasal**. A única restrição imposta por esta gramática é que as produções devem ter pelo menos um símbolo não-terminal em sua composição.
- **Tipo 1.** São as denominadas **gramáticas sensíveis ao contexto**. As produções deste tipo de gramática devem ser da forma $\alpha \rightarrow \beta$ onde $|\alpha| < |\beta|$ (evita que β seja vazia). Outra forma de descrever este tipo de gramática é representar as produções do tipo $\alpha \rightarrow \beta$ com $\alpha = \phi_1 A \phi_2$ e $\beta = \phi_1 \psi \phi_2$ (ϕ_1 e ϕ_2 possivelmente vazios) e com ψ não vazio. Assim, A é reescrito como ψ no **contexto** de ϕ_1 e ϕ_2 , daí o nome “sensível ao contexto” da gramática.

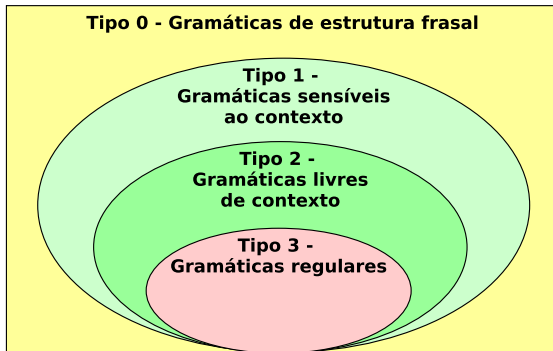
Hierarquia das linguagens

■ Classificação da gramáticas

- **Tipo 2.** São as denominadas **gramáticas livres de contexto**. É o tipo mais utilizado na descrição das linguagens de programação. As produções são da forma $\alpha \rightarrow \beta$ onde $|\alpha| \leq |\beta|$ e $\alpha \in V - \Sigma$, o que torna a gramática livre de contexto.
- **Tipo 3.** São as denominadas **gramáticas regulares** ou **lineares**. É muito utilizada **expressões regulares**, uma notação compacta que é empregada no reconhecimento de cadeias em compiladores, interpretadores, mecanismos de busca etc. As produções são da forma $\alpha \rightarrow \beta$ onde $|\alpha| \leq |\beta|$, $\alpha \in V - \Sigma$ e β possui a forma aB ou a , onde $a \in \Sigma$ e $B \in V - \Sigma$.

Hierarquia das linguagens

- **Hierarquia**



Teste seus conhecimentos

(1) Seja $V = \{S, A, B, a, b\}$. Determinar se $G = (V, \Sigma, R, S)$ é do tipo 0 (mas não do tipo 1), tipo 1 (mas não do tipo 2), tipo 2 (mas não do tipo 3) ou tipo 3, se R é um conjunto de produções como:

a) $R = \{S \rightarrow aAB, A \rightarrow Bb, B \rightarrow \epsilon\}$.

b) $R = \{S \rightarrow aA, aA \rightarrow B, B \rightarrow aA, A \rightarrow b\}$

c) $R = \{S \rightarrow aA, A \rightarrow bB, B \rightarrow b, B \rightarrow \epsilon\}$

Referências bibliográficas

- GERSTING, J. **Fundamentos Matemáticos para a Ciência da Computação: um Tratamento Moderno de Matemática Discreta.** [S.I.]: Livros Técnicos e Científicos. ISBN 9788521614227.
- RICH, E. **Automata, Computability and Complexity: Theory and Applications.** [S.I.]: Pearson Prentice Hall, 2008.
- ROSEN, K. **Discrete Mathematics and Its Applications.** New York: McGraw-Hill, 2003. (McGraw-Hill higher education).
- TAYLOR, R. G. **Models of computation and formal languages.** New York: Oxford University Press, 1998.